

IC7 CASE, ENGENHEIRO DE IA

# Campanha de Marketing Bancário

Previsão de Subscrição de Depósito a Prazo

Relatório Executivo, Fevereiro de 2026

## Em Síntese

11%

Taxa de conversão atual

70%

Redução potencial de  
chamadas

0,81+

Precisão do modelo  
(ROC-AUC)

# Conteúdo

---

<b>1</b>	<b>O Problema em Linguagem Acessível</b>	<b>2</b>
<b>2</b>	<b>O Que os Dados Revelaram</b>	<b>2</b>
2.1	Quem tende a subscrever . . . . .	2
2.2	Como o meio de contacto afeta o resultado . . . . .	3
2.3	Quando contactar . . . . .	3
2.4	O que não funciona . . . . .	4
<b>3</b>	<b>O Que o Modelo Consegue Fazer</b>	<b>4</b>
<b>4</b>	<b>As Nossas Recomendações</b>	<b>6</b>
<b>5</b>	<b>O Papel da Inteligência Artificial</b>	<b>7</b>
5.1	Porquê não usar IA Generativa para a previsão . . . . .	7
5.2	Onde a IA Generativa acrescenta valor real . . . . .	7
<b>6</b>	<b>Resumo e Próximos Passos</b>	<b>8</b>

# O Problema em Linguagem Acessível

O banco realiza campanhas de telemarketing para vender depósitos a prazo através de chamadas telefônicas. O processo atual consiste em contactar listas extensas de clientes sem qualquer critério de priorização. O resultado é que apenas 11 em cada 100 clientes contactados acabam por subscrever o produto.

## O Custo Real

Nove em cada dez chamadas não geram qualquer retorno. Com uma equipa de agentes a trabalhar em pleno, isto representa uma ineficiência estrutural: a maioria do tempo e orçamento da campanha é investida em pessoas que não irão subscrever, independentemente do número de tentativas.

O problema não é o produto nem a equipa de vendas. É a ausência de um critério inteligente para seleccionar a quem ligar e quando. O objetivo deste projeto é precisamente esse: substituir a abordagem aleatória por uma lista priorizada com base em dados.




Figura 1: Distribuição atual: apenas 11% dos clientes contactados subscrevem

## O Que os Dados Revelaram

Foram analisados mais de 41.000 registos de campanhas anteriores. Os padrões encontrados são consistentes e podem ser aproveitados de imediato.

### Quem tende a subscrever




Figura 2: Subscrição por resultado de campanha anterior




Figura 3: Subscrição por profissão

### Sinal mais Forte

Clientes contactados com sucesso em campanhas anteriores têm uma probabilidade de conversão dramaticamente superior. Estudantes e reformados apresentam taxas acima da média, possivelmente por maior disponibilidade e interesse em aplicações de poupança a longo prazo.

## Como o meio de contacto afeta o resultado




Figura 4: Volume de contactos por canal




Figura 5: Taxa de conversão por canal de contacto

O contacto por telemóvel supera consistentemente o telefone fixo em termos de taxa de conversão. Uma parte significativa dos registos históricos usa ainda o canal menos eficaz.

## Quando contactar




Figura 6: Taxa de conversão por mês de contacto

### Oportunidade de Calendário

Março, setembro, outubro e dezembro apresentam taxas de conversão notavelmente mais elevadas. Maio, apesar de ter o maior volume de chamadas no histórico, tem uma das piores taxas. A escolha do momento tem impacto direto nos resultados, independentemente do perfil do cliente.

## O que não funciona




Figura 7: Taxa Euribor nos clientes que subscreeveram vs. os que não subscreeveram

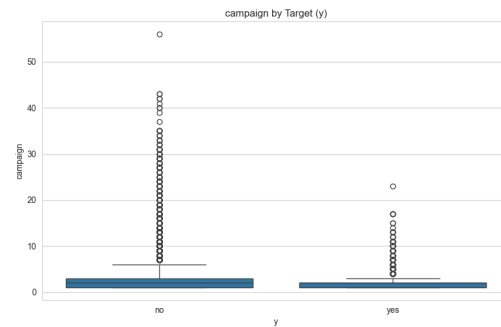


Figura 8: Número de chamadas por campanha vs. resultado

Insistir no mesmo cliente aumenta a frustração sem aumentar as conversões. Acima de duas ou três chamadas por campanha, o retorno diminui acentuadamente. O contexto económico, nomeadamente as taxas Euribor, também é um sinal relevante: períodos de taxas mais baixas coincidem com maior recetividade ao produto.

## O Que o Modelo Consegue Fazer

O modelo de machine learning desenvolvido analisa o perfil completo de cada cliente e atribui uma pontuação de probabilidade de subscrição, de 0 a 100%.

Na prática, isto transforma uma lista desordenada de milhares de clientes numa lista priorizada. Os agentes começam pelas pessoas com maior probabilidade de responder positivamente. Quando o orçamento da campanha se esgota, o banco já terá contactado os clientes certos.

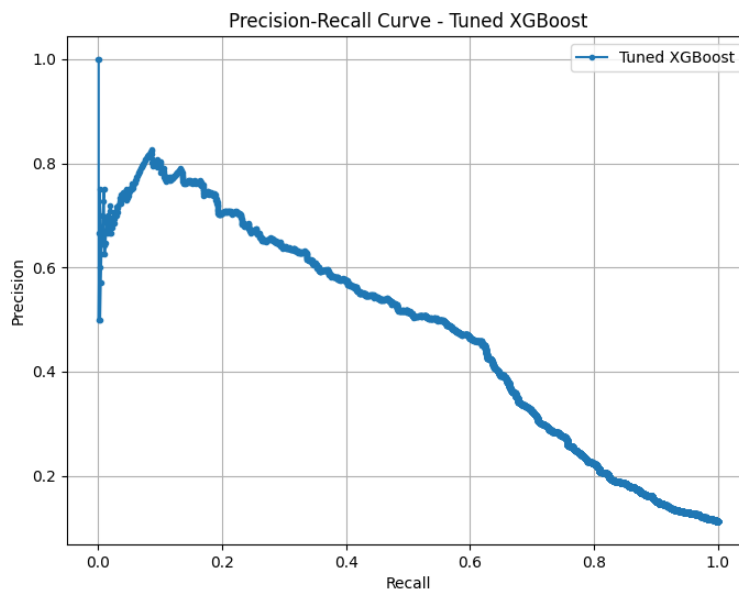


Figura 9: Desempenho do modelo final, XGBoost otimizado

#### Desempenho em Números Concretos

Em termos de detecção de subscritores, o modelo identifica corretamente 47% de todos os clientes que iriam subscrever, enquanto mantém uma precisão de 63% nas suas previsões positivas. Comparado com uma abordagem aleatória, isto representa 4 vezes mais eficiência na seleção de clientes.

#### Impacto Esperado

Ao trabalhar apenas com os 30% de clientes com maior pontuação, é possível capturar entre 60 e 70% de todas as subscrições. Com menos de um terço das chamadas, o banco recupera a maioria das conversões.

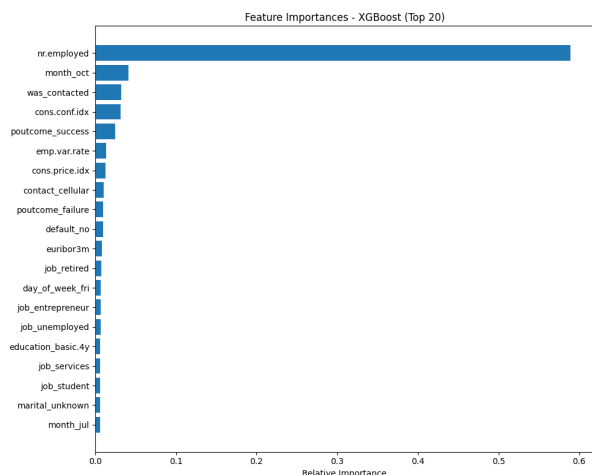


Figura 10: Variáveis mais relevantes para a previsão




Figura 11: Matriz de confusão do modelo final

## As Nossas Recomendações

As seguintes ações estão ordenadas por impacto esperado.

### 1. Implementar lista priorizada de chamadas

Antes de cada campanha, gerar automaticamente uma lista de clientes ordenada por probabilidade de subscrição. Os agentes trabalham sempre a partir desta lista, do topo para baixo.

### 2. Limitar o número de tentativas por cliente

Definir um máximo de duas chamadas por cliente em cada campanha. Chamadas adicionais têm retorno marginal e afetam negativamente a experiência do cliente.

### 3. Concentrar esforços nos períodos favoráveis

Intensificar a campanha em março, setembro, outubro e dezembro. Reduzir o volume nos meses com conversão historicamente baixa, como maio.

### 4. Dar prioridade ao canal telemóvel

Sempre que disponível, preferir o contacto por telemóvel ao telefone fixo. A diferença de taxa de conversão entre canais é estatisticamente significativa.

### 5. Atualizar registos com campos desconhecidos

Uma parte dos registos tem campos com valor desconhecido, que limitam a qualidade da previsão. Um esforço de atualização da base melhora o desempenho do modelo ao longo do tempo.

# O Papel da Inteligência Artificial

## Porquê não usar IA Generativa para a previsão

Para prever se um cliente vai subscrever ou não, os modelos tradicionais de machine learning são a escolha mais adequada. São mais transparentes, mais rápidos, mais baratos e muito mais fáceis de auditar. A interpretabilidade é especialmente importante num contexto financeiro regulado.

Usar um modelo generativo para esta tarefa seria o equivalente a usar uma ferramenta complexa para um problema que tem uma solução mais simples e mais fiável.

## Onde a IA Generativa acrescenta valor real

Tarefa	Abordagem	Recomen-	Porquê
	dada	dada	
Prever quem vai subscrever	Machine learning (XG-Boost)		Rápido, interpretável, auditável
Criar guiões de venda personalizados	IA Generativa		Adapta a mensagem ao perfil individual
Analisar gravações de chamadas	IA Generativa		Identifica padrões de sucesso em escala
Apoio ao agente em tempo real	IA Generativa		Sugere argumentos durante a conversa

### Recomendação

Usar machine learning para decidir a quem ligar. Usar IA generativa para apoiar como comunicar. As duas abordagens são complementares e não concorrentes.



## Resumo e Próximos Passos

---

- O banco tem uma taxa de conversão atual de 11% que pode ser melhorada substancialmente sem aumentar o orçamento.
- O modelo identifica os clientes com maior probabilidade de subscrição com uma precisão 4 vezes superior à abordagem aleatória.
- O investimento em infraestrutura é recuperado em semanas, dado o volume de chamadas que passam a ser evitadas.
- O modelo melhora ao longo do tempo à medida que acumula mais dados de campanhas subsequentes.

### A Oportunidade

Com o mesmo orçamento de chamadas, o banco pode obter resultados equivalentes ou superiores contactando menos de um terço dos clientes.

A proposta não substitui os agentes. Torna o trabalho deles mais eficiente, mais focado e com uma taxa de sucesso substancialmente mais elevada.